Demoday 2026

“Näe maailma ChatGPT:n silmin”

TURKUNLP
.ORG

- Turun yliopiston luonnollisen kielen prosessoinnin tutkimusryhmä
  - Perustettu vuonna 2001 ja tällä hetkellä ~30 tutkijaa
- Sekä tietotekniikkaa että kielentutkimusta
- NLP = natural language processing eli luonnollisen kielen käsittely / kieliteknologia
- Vahva fokus koneoppimismenetelmissä ja niiden soveltamisessa kielentutkimukseen

Keitä me olemme?

TURKUNLP
.ORG

Natural **L**anguage **P**rocessing

luonnollisen kielen käsittely / kieliteknologia

Mitä tarkoittaa “luonnollisen kielen prosessointi”?

- Luonnollinen kieli tarkoittaa jotakin ajan saatossa kehittynyttä kieltä, jota ihmiset käyttävät keskinäiseen kommunikointiin
  - Eli esimerkiksi ohjelmointikieli ei ole luonnollinen kieli
  - Ei kuitenkaan yksiselitteinen käsite (esim. Esperanto)

- Lyhenne NLP tulee sanoista Natural Language Processing
  - Tutkimusala, jolla tutkitaan luonnollisen kielen käyttöä datana
  - Juuret 1900-luvun alussa lingvistiikan ja tietojenkäsittelyn välimaastossa, eli lähtökohtaisesti monitieteellinen ala!

NLP + tekoäly = kielimallit

- Tekoälyä voi ajatella tietokoneohjelmana, joka pystyy oppimaan jotakin sille annetusta tiedosta
  - Erityisesti tekoäly on mahdollista kouluttaa näyttämällä tietynlaisia esimerkkejä
  - Näytetään tarpeeksi monta kuvaa kissoista -> tekoäly oppii tunnistamaan kissoja
- Kielimallit ovat sellaisia tekoälymalleja, jotka on koulutettu käsittelemään ja mahdollisesti tuottamaan jotakin luonnollista kieltä
  - Koulutetaan näyttämällä paljon ihmisten kirjoittamaa tekstiä
  - Useita erilaisia koulutustavoitteita:
    - Chatbotit ja tekoälyassistentit (esim. ChatGPT)
    - Relevanttien dokumenttien löytäminen (esim. Googlen hakukone)
    - Tekstien automaattinen tulkinta (esim. Wordin oikeinkirjoitusehdotukset)

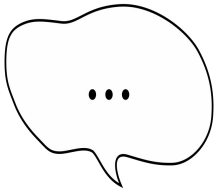

Keskustelu

Missä kieliteknologia näkyy arjessamme?

- Puhelinta käytettäessä?
- Google-hauissa?
- YouTubessa?

Missä kieliteknologia näkyy arjessamme?

Google Translate

ChatGPT

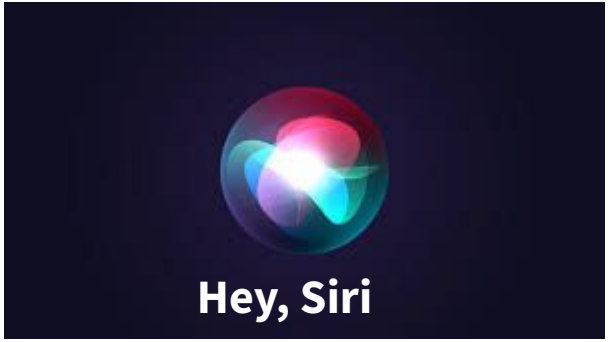

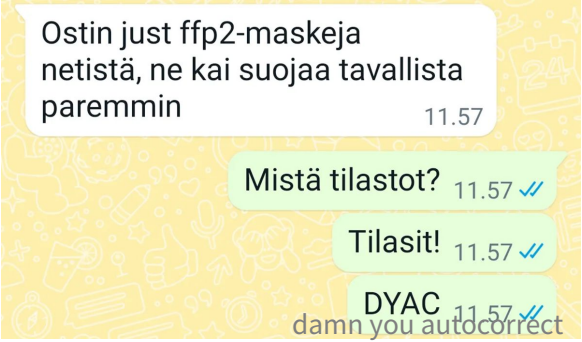

Keskustelu

Miksi ihmisten käyttämä kieli on vaikeaa koneille?

Mieti esimerkiksi näitä esimerkkejä:

“Aikuisen hirven luvalla saa ampua vasankin.”

“Hän oli ryhmän mätä omena.”

“Aikuisen hirven luvalla saa ampua vasankin.”

“Hän oli ryhmän mätä omena”

Miksi ihmisten käyttämä kieli on vaikeaa koneille?

- **Monimerkityksisyys**: sama ilmaus voi tarkoittaa useaa eri asiaa
  - Mies lähti kalaan ja sai seitin.
  - Aikuisen hirven luvalla saa ampua vasankin.
- **Vaihtelu**: sama merkitys voidaan sanoa usealla eri tavalla
  - Hän ei ole penaalin terävin kynä.
  - Hänellä ei ole kaikki muumit laaksossa.
  - Kielen vaihtelu ajassa ja paikassa: murteet, puhekielisyydet, ajallinen kehitys
- **Kuvainnollinen kieli**: ilmausta ei pidä tulkita kirjaimellisesti
  - Suksi kuuseen!
  - Hän oli ryhmän mätä omena.

Luonnollinen kieli numeroina 1/4

- Tietokoneet ymmärtävät vain numeroita, eivät sanoja tai kirjaimia
  - Siksi sanat täytyy muuttaa numeroiksi tietokoneita varten
- Numeroihin voidaan koodata sanan merkitys
  - Kielimalli oppii sanojen merkityksen niiden käyttökontekstista
- Mikä on wuptimuk?
  - “Onpas tuo wuptimuk karvainen!”
  - “Äiti tekee tänään wuptimuk-soppaa.”
  - “Varo, takanasi on wuptimuk!”

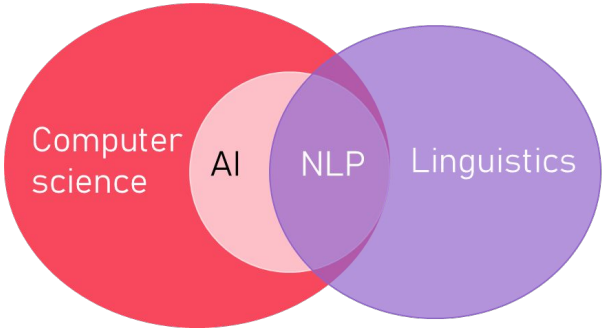

Luonnollinen kieli numeroina 2/2

- Alkujaan varattu yksi numero per yksi sana, kuten sanakirjoissa
  - Esim. minä=1, olen=24, iloinen=36 -> Minä olen iloinen -> [1, 24, 36]
  - Toimii yllättävän hyvin, mutta esim. monitulkintaisuus suuri ongelma…

- Nykyään kielimallit eivät tulkitse yksittäisiä sanoja yksittäisten numeroiden perusteella, vaan käytetään piirrevektoreita (eng. *embedding*)
  - Yksinkertaistettuna kielimallit on opetettu valtavalla määrällä ihmisten tuottamaa tekstiä, ja ne ovat oppineet tunnistamaan erilaisia piirteitä, jotka määrittelevät sanoja
    - Mallista riippuen kategorioita voi olla muutamista sadoista useisiin tuhansiin
  - Nykyiset mallit ovat kuitenkin niin monimutkaisia, että näitä kategorioita on vaikea määritellä tarkasti
    - “Kuinka puhekielinen sana on” tai “Liittyykö sana talouteen” voisivat olla esimerkkejä piirteiden määritelmistä

Luonnollinen kieli numeroina 2/4

“Varo, takanasi on wuptimuk!”

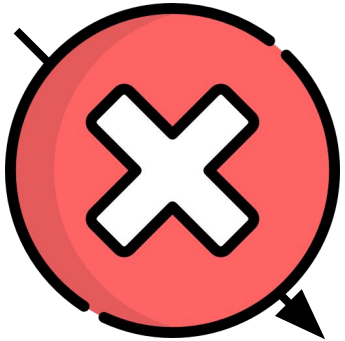

varo	87
,	1
takanasi	55
on	5
wuptimuk	99
!	2

→ [87, 1, 55, 5, 99, 2] →

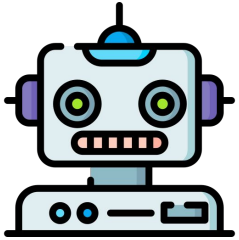

Luonnollinen kieli numeroina 3/4

“Varo, takanasi on wuptimuk!”

“Varo, takanasi on susi!”

“Varo, takanasi on hirvi!”

“Varo, takanasi on kaktus!”

“Äiti tekee tänään wuptimuk-soppaa.”

“Äiti tekee tänään jänis-soppaa.”

“Äiti tekee tänään hirvi-soppaa.”

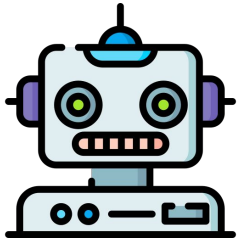

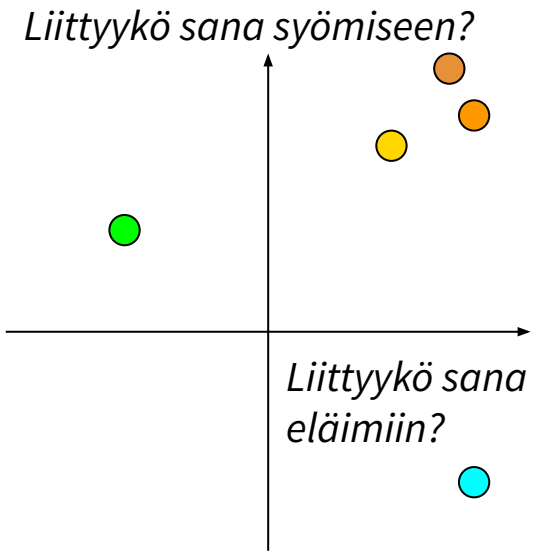

Muistetaan, että jokainen sana on muutettu numeroiksi!

Luonnollinen kieli numeroina 4/4

- Edellisellä dialla sanat oli kuvattu pisteinä x-y-koordinaatistossa
  - Tämä on yksinkertainen esimerkki siitä, miten sanoja nykyään kuvataan numeerisessa muodossa

Miten tehtiin ennen:

wuptimuk

↓

99

Miten tehdään nykyään:

wuptimuk

↓

[0.8, 0.75]

Onko kyseessä eläin?

Liittyykö sana syömiseen?

HUOM!
Oikeasti nämä vektorit ovat huomattavasti pidempiä eivätkä numerot kuvaa näin selkeitä kategorioita!

Lyhyt historiikki sanakirjoista ChatGPT:hen

- Alkuperäinen tavoite oli luoda automaattinen kääntäjä
  - Ihmiset käyttävät sanakirjoja käännöstyössä -> Pystyisikö myös tietokone tähän?
  - Sanakirjat ovat hyvä lähtökohta, mutta riittämätön luonnollisen kielen prosessoinnille
- Ensimmäiset neuroverkkomallit 1950-luvun lopulla
  - Valtava hype, odotukset “sähköisistä aivoista” ja ihmismäisistä koneista
  - Perustuivat silti ‘sanakirja-ajatteluun’ eli sääntöpohjaisuuteen ja pettivät odotukset…
- 1960-1990-luvuilla hidasta etenemistä, mutta suuria peruslaatuisia ongelmia
  - Liian vähän digitaalisia tekstiaineistoja, varsinkin ennen internetiä
  - Tietokoneet eivät olleet tarpeeksi tehokkaita
- 2000-luvulle tultaessa merkittäviä edistyksiä
  - Tärkeimpiä edistyksiä syväoppimisessa, käytettävän tekstiaineiston määrässä, sekä laskentatehossa
- Räjähdysmäinen kehitys vuodesta 2017 eteenpäin
  - Transformer-arkkitehtuuri julkisuuteen (esim. ChatGPT pohjautuu tähän)

Natural Language Processing

1950s
Suoritettiin helpohkoja ja rutiininomaisia käännöstehtäviä

1970 & 1980s
Hidasta etenemistä, koska ei tarpeeksi digitaalisia tekstiaineistoja ja tietokoneet eivät tarpeeksi tehokkaita

2000s
Käytettävän datan määrä kasvaa ja NLP pohjautuu yhä enemmän isoihin aineistoihin

2017
Transformers-arkkitehtuuri (esim. ChatGPT pohjautuu tähän)

1950s | 1960s | 1970s 1980s | 1990s | 2000s | 2010s | 2017 | 2023

1960s
Ensimmäiset koneoppimismallit, yksinkertaista automaattista tekstinkäsittelyä

1990s
Internetin läpimurto muuttaa tilannetta. Saatavilla olevan datan määrä kasvaa ja tilastollinen NLP nousee valtavirtaan

2010s
Merkittäviä edistyksiä tietokoneiden laskentatehossa ja syväoppimismalleissa

2023
Laajojen kielimallien (LLM) läpimurto ja laajamittainen käyttöönotto

Vektorien visualisointi

- Visualisoimalla vektoreita voimme nähdä vilauksen siitä, miltä maailma näyttää ChatGPT:n silmin
- Yksinkertaisimmillaan vektorit voi kuvata pisteinä
  - Lähekkäin toisiaan olevat pisteet ovat merkitykseltään samankaltaisia

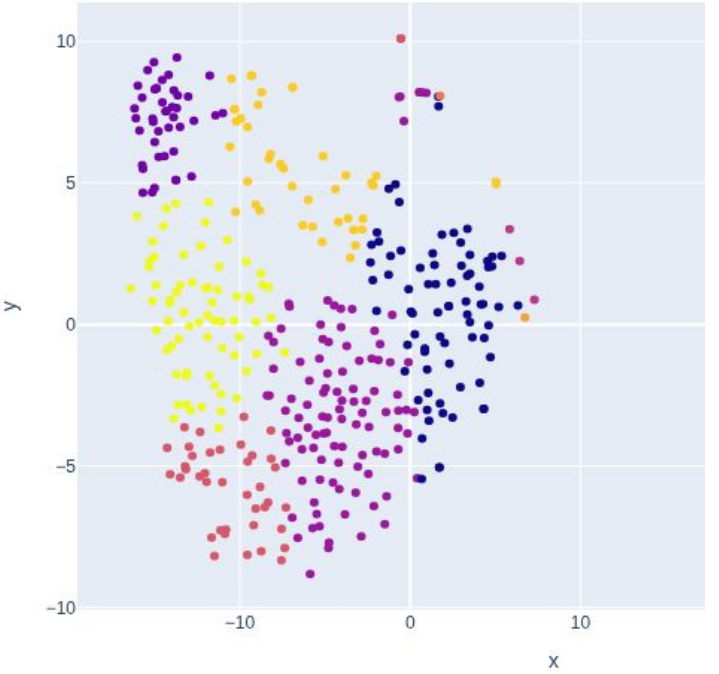

Ja sitten harjoituksiin!

- Harjoituksissa pääsette itse visualisoimaan sanavektoreita ja näin ymmärrätte, miten ChatGPT katsoo maailmaa!
- Harjoitukset tehdään Jupyter Notebook ympäristössä

Kiitos!